

Redes Bayesianas Gaussianas para la Enfermedad Renal Crónica

Estructuras elicidadas de especialistas, imputación por ecuaciones encadenadas y los límites del supuesto gaussiano en marcadores de laboratorio

Juan Pablo Venegas Padilla • Arie Zalo González
Santiago de la Calleja Jiménez • Juan Pablo Espinoza

Ingeniería en Ciencia de Datos y Matemáticas, Tecnológico de Monterrey • 7 de septiembre de 2026

Resumen. Este trabajo construye y evalúa **redes bayesianas gaussianas** (GBN) sobre 13 marcadores de laboratorio del dataset de **Enfermedad Renal Crónica** del repositorio UCI ($N = 400$). A diferencia de los estudios que aprenden la estructura de los datos, aquí las estructuras se **elicitan de especialistas**: se entrevistó a tres estudiantes de Medicina, cada uno propuso un grafo de dependencias y dos consultas de interés clínico. La metodología encadena limpieza y clasificación de variables, **imputación por ecuaciones encadenadas** (MICE) con el diagnóstico como variable auxiliar —los faltantes llegan a 49.6 % en pacientes enfermos contra 4.7 % en sanos, de modo que descartar filas sesgaría la muestra—, ajuste de una GBN por estructura, comparación por BIC y AIC, y respuesta a las seis consultas por muestreo lógico. La **DAG 2** resulta la mejor por ambos criterios (BIC = $-16,374.2$), y la diferencia decisiva es dónde cuelga la anemia: los datos favorecen hacerla depender de los marcadores de filtrado y no de los electrolitos, lo que coincide con que la eritropoyetina la produce el riñón. La red acierta el **sentido** de las seis consultas, pero no su magnitud, y este trabajo **cuantifica por qué**: solo 1 de 13 variables pasa la prueba de Shapiro–Wilk, el error relativo de cada consulta correlaciona con la asimetría de las variables implicadas ($\rho_{\text{Spearman}} = 0.898$, $p = 0.006$), y al condicionar sobre una cola la gaussiana **atenúa el co-movimiento** de las demás variables: predice una urea de 87.6 donde el grupo real promedia 143.6. Se documenta además que una búsqueda voraz sobre los datos supera a las tres propuestas por 278 puntos de BIC, pero a costa de orientaciones clínicamente imposibles. El trabajo cierra con dos extensiones: se desarrolla cómo entran las **variables categóricas** —red gaussiana condicional, con la diabetes confirmada por los datos en la posición que la clínica le asignaba (+120 puntos de BIC) y el diagnóstico como raíz discreta (+1,888)— y se evalúa si los **modelos no paramétricos** mejoran los criterios de información: el estimador kernel mejora el BIC nominal hasta en 3,620 puntos, pero ese número no es comparable y fuera de muestra la ventaja se desvanece; las ganancias reales vienen de una transformación monótona de las marginales más la mezcla condicional, que reducen el error medio de las consultas de 38.3 % a 24.9 %.

Palabras clave— Redes bayesianas gaussianas, enfermedad renal crónica, elicitación de expertos, imputación múltiple, MICE, **bnlearn**, supuesto de normalidad, inferencia condicional.

1. Introducción

La enfermedad renal crónica (ERC) es un deterioro progresivo y en buena medida silencioso de la función renal: cuando aparecen los síntomas, el daño suele estar avanzado [13]. Su diagnóstico y seguimiento descansan en un puñado de marcadores de laboratorio —creatinina sérica, urea, densidad urinaria, albuminuria, electrolitos y biometría hemática— cuyas relaciones los clínicos conocen bien, pero que rara vez se formalizan en un modelo probabilístico conjunto.

Ese es el punto de partida de este trabajo. Los 400 pacientes del dataset de ERC del repositorio UCI [15] traen esos marcadores medidos, y las relaciones entre ellos son exactamente el tipo de

conocimiento que un modelo gráfico puede representar. La pregunta que organiza el estudio no es si un algoritmo puede descubrir esa estructura, sino algo más cercano a la práctica clínica: **si se le pide a un médico que dibuje cómo cree que se relacionan estas variables, ¿qué tan bien se sostiene su dibujo frente a los datos, y qué tan lejos llegan las respuestas que se pueden obtener de él?**

1.1. Antecedentes y estado del arte

Una red bayesiana codifica una distribución conjunta mediante un grafo acíclico dirigido (DAG) en el que cada arco $A \rightarrow B$ afirma una dependencia directa [1, 2]. Cuando todas las variables son continuas y cada nodo se modela como una regresión lineal sobre sus padres con residuo normal, la red se llama **gaussiana**: la distribución conjunta resultante es una normal multivariada y sus parámetros se estiman por mínimos cuadrados [3, 4]. Esta familia es atractiva porque el ajuste es cerrado y barato, y porque cada arco tiene una lectura inmediata —un coeficiente de regresión— que un especialista puede discutir.

Su precio es el supuesto. Una GBN obliga a cada variable a ser normal condicionalmente a sus padres y a que toda dependencia sea lineal. Cuando los datos son marcadores de laboratorio —donde lo clínicamente relevante suele estar justamente en la cola— ese supuesto es fuerte. La extensión natural son las **redes gaussianas condicionales** (CLGBN) de Lauritzen y Wermuth [5, 6], que admiten nodos discretos siempre que no tengan padres continuos. La implementación de referencia de ambas familias es el paquete **bnlearn** [8], que provee el ajuste, los criterios de información de Akaike [9] y Schwarz [10], y la inferencia aproximada por muestreo lógico.

En el ámbito biomédico, las redes bayesianas se han usado para diagnóstico, pronóstico y análisis de dependencias entre hallazgos clínicos desde hace tres décadas [11, 12]. La elicitación de estructura con expertos, en particular, es un procedimiento reconocido cuando el tamaño de muestra no alcanza para que el aprendizaje automático identifique orientaciones confiables: el grafo aporta el conocimiento causal que los datos por sí solos no contienen.

El otro problema que este dataset impone es el de los datos faltantes. La distinción de Rubin [16] entre faltantes completamente al azar, al azar y no al azar es decisiva aquí: como se documenta más abajo, la ausencia de dato está fuertemente asociada al diagnóstico, así que eliminar registros incompletos vaciaría selectivamente el grupo enfermo. La imputación por ecuaciones encadenadas [18, 17] resuelve el problema con una lógica que, además, coincide con la del modelo que se va a ajustar: cada variable se estima como una regresión de las demás.

1.2. Problema y preguntas de investigación

Se entrevistó a tres personas de la Escuela de Medicina del campus —un estudiante de 5º semestre y dos de 9º—. Cada una propuso una estructura de dependencias entre las 13 variables continuas y dos consultas que le interesaría resolver con el modelo:

- C1 $P(\text{creatinina} > 3 \mid \text{presión} \geq 90)$.
- C2 $E[\text{hematocrito} \mid \text{hemoglobina} < 10]$.
- C3 $E[\text{hemoglobina} \mid \text{creatinina} > 5]$.
- C4 $P(\text{potasio} > 5.5 \mid \text{urea} > 100)$.
- C5 $E[\text{albúmina} \mid \text{glucosa} < 140]$ frente a $E[\text{albúmina} \mid \text{glucosa} > 200]$.
- C6 $P(\text{creatinina} > 3 \mid \text{diabetes})$.

Las preguntas de investigación son tres: ¿cuál de las tres estructuras propuestas se ajusta mejor a los datos y en qué difieren sustantivamente?; ¿qué respuestas produce la mejor red a las seis consultas y qué tan cerca están de lo que muestran los datos?; y ¿cómo entra al modelo una variable categórica como la diabetes, que una GBN pura no admite?

1.3. Objetivos

General: construir, comparar y validar redes bayesianas gaussianas sobre los marcadores de laboratorio de la ERC a partir de estructuras elicidadas de especialistas, y responder con la

mejor de ellas las consultas clínicas planteadas. **Específicos:** (i) limpiar el dataset y separar las variables que una GBN admite de las que no; (ii) imputar los faltantes con un método compatible con el modelo y validar que la señal clínica se conserve; (iii) formalizar las tres estructuras y verificar su aciclicidad; (iv) ajustarlas y compararlas por BIC y AIC; (v) responder las seis consultas y contrastarlas contra la evidencia empírica; y (vi) diagnosticar el supuesto gaussiano y cuantificar su efecto sobre las respuestas.

1.4. Aportaciones

1. Un flujo **reproducible y auditable** que va del CSV crudo —con tokens de texto incrustados en columnas numéricas— a una base imputada lista para modelar, con la validación de que la imputación no desplaza las diferencias clínicas entre grupos.
2. La **formalización de tres estructuras elicidadas de especialistas** y su comparación cuantitativa, incluyendo el caso de una relación clínicamente real —la retroalimentación de los electrolitos sobre la presión arterial— que un DAG no puede representar por ser cíclica.
3. Un **diagnóstico cuantitativo del supuesto gaussiano** que explica, variable por variable y consulta por consulta, por qué la red acierta el sentido pero falla la magnitud: el error relativo correlaciona con la asimetría ($\rho = 0.898$, $p = 0.006$) y la condicional gaussiana atenúa el co-movimiento de las colas de forma medible.
4. Un **contraste contra una búsqueda voraz** sobre los mismos datos, que gana 278 puntos de BIC pero produce orientaciones imposibles —la edad como efecto del conteo de eritrocitos—, delimitando qué aporta el experto y qué aportan los datos.
5. Un **estudio de la incorporación de variables categóricas**: la formalización de la red gaussiana condicional, la búsqueda de la mejor posición para la diabetes —que confirma la elección clínica y a la vez expone la fuga del diagnóstico—, el diagnóstico como raíz discreta y el costo medido de la alternativa de discretizar.
6. Una **evaluación de nueve variantes no paramétricas y semiparamétricas** bajo tres criterios (BIC, AIC y verosimilitud fuera de muestra), que muestra por qué el BIC no es un criterio válido para componentes no paramétricos y qué relajaciones sí mejoran las respuestas del modelo.

2. Metodología

2.1. Arquitectura del flujo de trabajo

El proyecto se divide en dos etapas con lenguajes distintos. La **preparación** corre en Python con `pandas` [31] y `scikit-learn` [30] sobre dos cuadernos —análisis exploratorio e imputación— y produce un único archivo, `ckd_imputado.csv`. El **modelado** corre en R con `bnlearn` [8, 32] sobre dos documentos Quarto: uno que formaliza las estructuras elicidadas y otro que las ajusta y responde las consultas. La Fig. 1 resume las cinco fases. Todo el código está disponible en https://github.com/JuanPabloEspTEC/MRI-art_2-RBG.




Figura 1: Metodología propuesta, en cinco fases secuenciales.

2.2. Datos y limpieza

El dataset de ERC del repositorio UCI [15] reúne **400 pacientes** y 25 variables —24 atributos más el diagnóstico— recolectados en un hospital a lo largo de aproximadamente dos meses. El diagnóstico está desbalanceado: **250 casos ckd** contra **150 notckd** (62.5 % / 37.5 %).

La inspección inicial detectó cuatro problemas, resumidos en la Tabla 1. El más insidioso es el tercero: `pcv`, `wc` y `rc` son conteos hematológicos, pero llegaban como texto porque algunas celdas contenían el token `'\t?'`. Leídas así, esas tres variables quedan fuera de cualquier cálculo numérico sin que nada lo advierta; convertidas correctamente, el token pasa a contarse como el dato faltante que en realidad es.

Tabla 1: Problemas detectados en el archivo original y acción tomada.

Problema	Acción
<code>id</code> tiene 400 valores únicos: es un identificador, no una variable.	Se elimina la columna.
<code>classification</code> reporta 3 niveles cuando el diagnóstico solo puede ser <code>ckd</code> o <code>notckd</code> ; <code>dm</code> reporta 5 y <code>cad</code> 3.	Se normaliza el texto (espacios y tabuladores); quedan 2 niveles en cada una.
<code>pcv</code> , <code>wc</code> y <code>rc</code> son numéricas pero pandas las lee como texto por el token <code>'\t?'</code> .	Se convierten a <code>float64</code> ; el token pasa a contarse como faltante.
Los faltantes no son menores: <code>rbc</code> 38 %, <code>rc</code> 32.5 %, <code>wc</code> 26.3 %.	Se analizan por grupo diagnóstico antes de decidir la estrategia (§2.4).

2.3. Qué variables admite una red gaussiana

Esta es la decisión que condiciona todo lo demás: **una red bayesiana gaussiana solo admite variables continuas**. De las 25 columnas, 11 son categóricas y una más (`su`, azúcar en orina) es un conteo ordinal de seis niveles, de modo que **13 variables** quedan disponibles para el modelo: `age`, `bp`, `sg`, `al`, `bgr`, `bu`, `sc`, `sod`, `pot`, `hemo`, `pcv`, `wc` y `rc`. El propio diagnóstico queda fuera de las estructuras, y en §3.5 se muestra cómo reincorporarlo.

Conviene dejar asentada una tensión que el análisis exploratorio ya señalaba. Tres de esas 13 variables son, estrictamente, ordinales o redondeadas: `bp` se registró en múltiplos de 10 y toma 10 valores distintos, `sg` toma 5 y `al` toma 6. Se conservan como continuas —sin ellas la

cascada clínica se rompe—, pero su naturaleza discreta reaparece en el diagnóstico del supuesto gaussiano de §3.7.

2.4. Faltantes e imputación

El patrón de faltantes no es aleatorio. La Tabla 2 lo muestra desglosado por diagnóstico: en `rc` falta el **49.6 %** de los datos entre pacientes enfermos y apenas el **4.7 %** entre sanos, y el mismo contraste se repite en todas las variables. La lectura clínica es transparente —a un paciente sano no se le piden los mismos estudios que a uno en protocolo de ERC—, pero la consecuencia estadística es seria: solo **203 de 400** filas están completas en las 13 continuas (158 si se exigen las 25 variables), y descartar las incompletas vaciaría selectivamente el grupo enfermo. Es un caso de libro de faltantes no aleatorios [16], donde el análisis de casos completos sesga.

Tabla 2: Las 13 variables continuas del modelo y su porcentaje de faltantes, desglosado por diagnóstico.

Variable	Significado	% total	% ckd	% notckd
<code>rc</code>	Eritrocitos	32.8	49.6	4.7
<code>wc</code>	Leucocitos	26.5	39.6	4.7
<code>pot</code>	Potasio sérico	22.0	33.2	3.3
<code>sod</code>	Sodio sérico	21.8	32.8	3.3
<code>pcv</code>	Hematocrito	17.8	26.8	2.7
<code>hemo</code>	Hemoglobina	13.0	18.4	4.0
<code>sg</code>	Densidad urinaria	11.8	16.8	3.3
<code>al</code>	Albúmina en orina	11.5	16.4	3.3
<code>bgr</code>	Glucosa en sangre	11.0	15.2	4.0
<code>bu</code>	Urea en sangre	4.8	5.2	4.0
<code>sc</code>	Creatinina sérica	4.2	4.8	3.3
<code>bp</code>	Presión arterial	3.0	4.0	1.3
<code>age</code>	Edad	2.2	3.2	0.7

Se evaluaron tres alternativas. La imputación por media o mediana es simple pero ignora la relación entre variables y reduce artificialmente la varianza. El vecino más cercano (KNN) considera la similitud entre pacientes pero es muy sensible a la escala, y aquí las escalas van de 1.02 (densidad urinaria) a 8,400 (leucocitos). Se eligió **MICE** (`IterativeImputer`, `random_state = 42`, `max_iter = 15`) por una razón de fondo: su lógica es la misma que la del modelo que se va a ajustar —cada variable como combinación lineal de las demás bajo supuesto gaussiano—, de modo que la imputación no introduce una estructura ajena a la red [18]. Como los faltantes dependen del diagnóstico, este se incluyó codificado como 0/1 durante la imputación y se descartó al terminar.

2.5. Redes bayesianas gaussianas

Sea $\mathbf{X} = (X_1, \dots, X_p)$ un vector de variables continuas y $\mathcal{G}$ un DAG sobre ellas. La red factoriza la conjunta según la estructura del grafo,

$$f(x_1, \dots, x_p) = \prod_{i=1}^p f(x_i \mid \text{pa}(x_i)), \quad (1)$$

y en el caso gaussiano cada factor es una regresión lineal con residuo normal:

$$X_i \mid \text{pa}(X_i) \sim \mathcal{N}\left(\beta_{i0} + \sum_{X_j \in \text{pa}(X_i)} \beta_{ij} X_j, \sigma_i^2\right). \quad (2)$$

Ajustar la red es, por tanto, estimar para cada nodo un intercepto, un coeficiente por padre y la desviación estándar de los residuos; con `method = "mle-g"` esto se resuelve por mínimos

cuadrados ordinarios nodo por nodo [3, 4]. La conjunta resultante es una normal multivariada cuya matriz de covarianzas queda determinada por los coeficientes y las varianzas residuales.

La comparación entre estructuras usa los dos criterios de información en su versión gaussiana, en la convención de **bnlearn** donde un valor **mayor** indica mejor ajuste:

$$\text{BIC}(\mathcal{G}) = \log \hat{L}(\mathcal{G}) - \frac{\log n}{2} |\Theta_{\mathcal{G}}|, \quad (3)$$

$$\text{AIC}(\mathcal{G}) = \log \hat{L}(\mathcal{G}) - |\Theta_{\mathcal{G}}|, \quad (4)$$

donde $|\Theta_{\mathcal{G}}| = \sum_i (|\text{pa}(X_i)| + 2)$ cuenta interceptos, coeficientes y desviaciones residuales. Para medir el aporte de cada arco se usa **arc.strength** con criterio **bic-g**, que reporta **el cambio en el BIC si el arco se elimina**: un valor negativo significa que quitarlo empeora el modelo —el arco está sostenido por los datos— y uno positivo, que sobra.

2.6. Inferencia

Las consultas se responden con **cpquery** (probabilidades) y **cpdist** (valores esperados sobre la distribución condicional simulada), ambas por **muestreo lógico**: se generan realizaciones de la red, se descartan las incompatibles con la evidencia y se calcula la proporción o el promedio sobre las restantes. Se usan 10^6 muestras para las probabilidades y 10^5 para las esperanzas, con semilla fija (**set.seed(42)**). Cada respuesta se acompaña de la frecuencia observada en los datos, calculada sobre el mismo universo, como referencia.

2.7. Cómo entran las variables categóricas

Ni el diagnóstico ni la diabetes son continuos, de modo que ninguno cabe en una GBN pura. La literatura ofrece tres caminos, con costos distintos.

(a) **Red gaussiana condicional (CLGBN)**. Es la extensión canónica del modelo gaussiano a variables mixtas [5, 6]. Se parte el conjunto de nodos en discretos **D** y continuos **Y**, y la conjunta se escribe como el producto de una distribución discreta por una gaussiana *condicionada a la configuración discreta*:

$$f(\mathbf{d}, \mathbf{y}) = p(\mathbf{d}) \prod_{Y_i \in \mathbf{Y}} \mathcal{N}\left(y_i \mid \beta_{i0}^{(\mathbf{d}_i)} + \sum_{Y_j \in \text{pa}_c(Y_i)} \beta_{ij}^{(\mathbf{d}_i)} y_j, (\sigma_i^{(\mathbf{d}_i)})^2\right), \quad (5)$$

donde $\mathbf{d}_i$ es la configuración de los padres discretos de Y_i y $\text{pa}_c(Y_i)$ sus padres continuos. En palabras: **cada nodo continuo tiene una regresión distinta por cada combinación de sus padres discretos**. La restricción del formalismo es que **un nodo discreto no puede tener padres continuos**, y la razón es estructural, no computacional: si un nodo discreto dependiera de uno continuo, la marginal del continuo dejaría de ser una mezcla finita de gaussianas y la familia perdería el cierre que hace tratable la inferencia. El costo en parámetros es multiplicativo: un nodo continuo con k padres continuos y padres discretos con $|\mathbf{d}_i|$ configuraciones pasa de $k + 2$ a $|\mathbf{d}_i|(k + 2)$ parámetros.

(b) **Discretizar todo y usar una red multinomial**. Funciona con cualquier combinación de variables y es la opción del artículo anterior de esta serie, pero paga el precio de agrupar en intervalos: en un marcador con cola larga, casi toda la masa cae en el primer intervalo y la variable se vuelve, en la práctica, constante (§3.6.4 lo cuantifica).

(c) **Codificar la categoría como 0/1 y tratarla como continua**. Es la más fácil y la menos defendible: le asigna una distancia numérica a algo que no la tiene, obliga a una binaria a ser normal y, en la inferencia, produce valores intermedios sin interpretación —¿qué es un paciente con diabetes = 0.4?—.

Se adoptó la primera. La §3.6 la desarrolla: dónde conviene colocar la variable discreta según los datos, qué pasa cuando el discreto es el propio diagnóstico y cuánto cuesta cada alternativa.

2.8. Modelos no paramétricos y semiparamétricos

La segunda pregunta de este trabajo es si relajar el supuesto gaussiano —el que §3.8 muestra violado— mejora el ajuste medido por BIC y AIC. Conviene precisar qué significa “no paramétrico” dentro de una red bayesiana, porque hay al menos cuatro familias:

1. **CPD por estimación de densidad kernel.** Se conserva el DAG pero la densidad condicional de cada nodo se estima con un núcleo en lugar de una normal [21, 27]. Es la opción más flexible y la que menos supuestos hace.
2. **Redes bayesianas semiparamétricas.** Cada nodo elige entre una CPD lineal gaussiana y una CPD por kernel condicional, y la elección se hace por **verosimilitud validada cruzadamente** [22]. Es el punto medio entre (1) y el modelo gaussiano.
3. **Transformaciones monótonas de las marginales.** La familia nonparanormal o de cópula gaussiana [23, 24] transforma cada variable para que su marginal sea normal y conserva la estructura gaussiana en el espacio transformado. Sus versiones paramétricas son las transformaciones de potencia de Box–Cox [19] y Yeo–Johnson [20], que admiten zeros y valores negativos.
4. **Mezclas de exponenciales truncadas o de polinomios** (MTE, MOP) [25, 26], que aproximan cualquier densidad por trozos manteniendo la propagación exacta.

Aquí aparece un problema de método que conviene declarar antes de reportar cualquier número. **El BIC no está definido para un componente no paramétrico.** La derivación de Schwarz [10] supone una familia paramétrica de dimensión fija, y la penalización $\frac{1}{2} \log n \cdot |\Theta|$ cuenta esos parámetros; un estimador kernel no tiene un $|\Theta|$ que contar —sus grados de libertad efectivos crecen con n — de modo que aplicarle la fórmula subestima su complejidad y sesga la comparación a su favor. Por eso la literatura semiparamétrica [22, 28] selecciona por **verosimilitud fuera de muestra**. En §3.9 se reportan las tres cifras —BIC nominal, AIC nominal y log-verosimilitud validada cruzadamente en 5 particiones— y se muestra que llevan a conclusiones distintas.

Dos precisiones técnicas más. Primero, comparar modelos ajustados sobre datos transformados exige **devolver la verosimilitud a la escala original** sumando el logaritmo del jacobiano de la transformación; sin esa corrección, cualquier transformación que comprima la escala “mejora” el puntaje de manera espuria. Para Yeo–Johnson con $x \geq 0$ el jacobiano es $(\lambda - 1) \sum_i \log(x_i + 1)$, y los λ estimados por máxima verosimilitud se cuentan como parámetros adicionales. Segundo, la verosimilitud de los modelos con kernel se calcula **dejando fuera el propio punto** (*leave-one-out*), para que la densidad de cada observación no esté inflada por su propia contribución.

3. Aplicación y resultados

3.1. Imputación y validación

Tras la imputación, la base queda en **400 filas $\times$ 13 columnas sin un solo faltante**. La validación consistió en comparar las medias por grupo diagnóstico antes y después (Tabla 3): si la imputación hubiera desplazado el centro de las distribuciones o diluido las diferencias clínicas, no serviría como insumo del modelo.

Tabla 3: Medias por grupo diagnóstico antes y después de imputar. Las diferencias clínicas se conservan.

Variable	ckd ($n = 250$)		notckd ($n = 150$)	
	antes	después	antes	después
age	54.54	54.48	46.52	46.53
bp	79.62	79.46	71.35	71.36
sg	1.01	1.01	1.02	1.02
al	1.72	1.76	0.00	0.00
bgr	175.42	172.37	107.72	108.59
bu	72.39	72.08	32.80	32.82
sc	4.41	4.34	0.87	0.92
sod	133.90	134.63	141.73	141.71
pot	4.88	4.68	4.34	4.33
hemo	10.65	10.82	15.19	15.17
pcv	32.94	33.29	46.34	46.32
wc	9069.54	8841.66	7705.59	7730.67
rc	3.95	4.06	5.38	5.37

Las medias apenas se mueven, y todas las diferencias documentadas en el análisis exploratorio sobreviven: la hemoglobina, el hematocrito y los eritrocitos siguen siendo notablemente más bajos en los enfermos —la anemia asociada a la ERC—, mientras que la creatinina, la urea y la glucosa siguen siendo más altas. Un efecto lateral merece mención: al imputar variables ordinales aparecen valores fuera de la escala de medición, como densidades urinarias intermedias entre los cinco niveles que el laboratorio reporta. Es el precio de tratarlas como continuas y se retoma en §3.7.

3.2. Las tres estructuras propuestas

Las Figs. 2–4 muestran las tres estructuras elicidadas y la Tabla 4 las compara.

La **DAG 1**, del estudiante de 5º semestre, describe la ERC como una cascada estricta: la edad y la glucosa inician el daño, la presión arterial arranca la fisiopatología y el deterioro avanza etapa por etapa —marcadores urinarios, marcadores de filtrado, electrolitos, serie roja— hasta la anemia y la inflamación. Durante la entrevista el estudiante señaló además que la acumulación de sodio y potasio vuelve a elevar la presión arterial. Esa observación es clínicamente correcta y **no se puede representar**: los arcos $sod \rightarrow bp$ y $pot \rightarrow bp$ cierran un ciclo y `bnlearn` los rechaza con el mensaje “*the specified network contains cycles*”. Es una limitación del formalismo, no del conocimiento del experto: los DAGs no admiten retroalimentación, y modelar un lazo así exige una red dinámica con la variable indexada en el tiempo.

La **DAG 2**, del primer estudiante de 9º semestre, conserva la forma de cascada pero introduce dos cambios: separa la edad como origen de las dos causas principales de ERC —la hipertensión y la diabetes— y hace colgar la anemia **directamente de los marcadores de filtrado** (**sc** y **bu**) en lugar de los electrolitos, con el argumento de que la eritropoyetina la produce el riñón dañado [14].

La **DAG 3**, del segundo estudiante de 9º semestre, separa explícitamente las dos vías de daño: la diabetes actúa sobre el glomérulo produciendo albuminuria y la hipertensión sobre el túbulo produciendo pérdida de concentración urinaria; ambas convergen en los marcadores de filtrado. Añade además el descenso del filtrado por edad ($age \rightarrow sc$) y es la más parsimoniosa de las tres.




Figura 2: DAG 1 (estudiante de 5º semestre) — la ERC como cascada estricta; la anemia cuelga de los electrolitos.




Figura 3: DAG 2 (9º semestre, A) — la edad como origen de las dos causas principales y la anemia colgando de los marcadores de filtrado. Es la estructura seleccionada por BIC y AIC.




Figura 4: DAG 3 (9º semestre, B) — dos vías de daño separadas, glomerular y tubular, que convergen en los marcadores de filtrado.

Tabla 4: Comparación estructural de las tres propuestas. Los conteos $tp/fp/fn$ y la distancia estructural (SHD) toman la DAG 1 como referencia.

Estructura	Arcos	Acíclica	tp	fp	fn	SHD vs. DAG 1
DAG 1 (5º sem)	20	sí	—	—	—	—
DAG 2 (9º sem A)	19	sí	14	5	6	11
DAG 3 (9º sem B)	17	sí	12	5	8	15

SHD entre las dos propuestas de 9º semestre: **6**.

Las tres coinciden en la parte inicial de la cascada —la DAG 2 comparte 14 de los 20 arcos de la DAG 1 y la DAG 3 comparte 12— y se separan en el tramo final: en cómo llega el daño renal a la anemia. Las dos propuestas de 9º semestre son las más parecidas entre sí (SHD = 6), lo que sugiere que la formación adicional converge hacia una misma lectura del mecanismo.

3.3. Ajuste y comparación de las tres redes

Se ajustó una GBN por estructura sobre las 400 observaciones imputadas. La Tabla 5 reporta ambos criterios.

Tabla 5: Comparación de las tres GBN sobre las 400 observaciones imputadas. Valores mayores indican mejor ajuste. La última columna es una reproducción independiente del BIC, implementada desde cero en Python.

Estructura	Arcos	BIC	AIC	BIC (verif.)
DAG 1 (5º sem)	20	−16,620.07	−16,528.26	−16,620.01
DAG 2 (9º sem A)	19	−16,374.23	−16,284.42	−16,374.18
DAG 3 (9º sem B)	17	−16,453.82	−16,368.00	−16,453.77

Los dos criterios coinciden en el orden, lo que hace la conclusión robusta: la **DAG 2** es la mejor, seguida de la DAG 3 y al final la DAG 1. La ventaja de la DAG 2 sobre la DAG 1

es de **245.8 puntos de BIC** y sobre la DAG 3 de 79.6, distancias que no dejan lugar a la duda —a diferencia de lo que ocurre cuando dos estructuras difieren en unas pocas unidades—. Como verificación, los tres puntajes se recalcularon implementando (3) desde cero en Python a partir de las regresiones nodo por nodo; las diferencias con `bnlearn` son menores a 0.07 puntos, atribuibles al redondeo en la estimación de las desviaciones residuales.

Lo que decide la comparación es exactamente el punto en que las estructuras discrepan: dónde cuelga la anemia. La DAG 1 la hace depender del sodio y el potasio; las DAG 2 y 3, de la creatinina y la urea. **Los datos favorecen la segunda opción**, que es también la que la fisiología respalda: la eritropoyetina se produce en el riñón y su caída acompaña al deterioro del filtrado, no al desbalance electrolítico [14]. Es un caso en que el criterio estadístico y el argumento clínico apuntan en la misma dirección.

3.4. Fuerza de los arcos

La Tabla 6 reporta `arc.strength` sobre la DAG 1 con criterio `bic-g`, es decir, el cambio en el BIC si cada arco se eliminara.

Tabla 6: Fuerza de los arcos de la DAG 1 (cambio en BIC al eliminar el arco). Valores negativos indican que los datos sostienen el arco; el único positivo sobra.

Desde	Hacia	Fuerza	Desde	Hacia	Fuerza
sc	sod	−145.68	bu	sod	−13.67
hemo	pcv	−124.01	pot	rc	−10.79
al	bu	−28.42	pot	hemo	−7.09
bu	pot	−24.37	sg	sc	−4.49
sod	hemo	−24.08	pcv	wc	−3.22
bgr	al	−22.44	bp	sg	−2.40
rc	pcv	−22.11	age	bp	−2.07
sod	rc	−21.53	bp	al	−0.69
bgr	sg	−20.16	sg	bu	−0.39
al	sc	−20.05	sc	pot	+0.24

Diecinueve de los veinte arcos tienen fuerza negativa: los datos los sostienen. El único con signo positivo es `sc` $\rightarrow$ `pot`, de modo que la DAG 1 mejoraría —marginalmente, 0.24 puntos— si se quitara. Los dos arcos más fuertes, `sc` $\rightarrow$ `sod` (−145.7) y `hemo` $\rightarrow$ `pcv` (−124.0), reflejan las dos asociaciones más intensas del conjunto: la correlación entre creatinina y sodio es de −0.72 y la de hemoglobina con hematocrito, de 0.90. Esta última merece una advertencia: hemoglobina, hematocrito y eritrocitos miden prácticamente lo mismo, y un arco muy fuerte entre ellos habla más de redundancia que de mecanismo.

3.5. Parámetros de la red elegida

En una GBN cada nodo es una regresión, así que los parámetros se leen directamente. Dos ejemplos de la DAG 2 ajustada:

$$\text{sc} = 203.487 - 198.667 \text{ sg} + 1.475 \text{ al}, \quad \sigma = 4.923; \quad (6)$$

$$\text{hemo} = 14.352 - 0.0326 \text{ bu} - 0.0096 \text{ sc}, \quad \sigma = 2.228. \quad (7)$$

La ecuación (6) es coherente con la clínica: la creatinina sube cuando la densidad urinaria baja —el riñón pierde capacidad de concentrar— y sube con la albuminuria. La (7) anticipa un problema que reaparecerá en la consulta 3: el coeficiente de la creatinina sobre la hemoglobina es de apenas −0.0096 por mg/dL, casi nulo, de modo que en el modelo la creatinina prácticamente no mueve la hemoglobina. El ajuste completo explica el 35.5 % de la varianza de la hemoglobina.

3.6. Variables categóricas en la red

3.6.1 La diabetes como nodo discreto

Para responder la consulta 6 se extendió la DAG 2 con un nodo discreto, la diabetes (**dm**: 261 pacientes sin, 137 con), colocado como padre de la glucosa. El ajuste con **mle-cg** produce una densidad condicional distinta por nivel del padre discreto:

bgr dm + age	dm = no	dm = sí
Intercepto	96.05	225.41
Coefficiente de age	0.51	−0.36
Desv. residual	39.15	96.07

La glucosa queda con una media muy distinta según el diagnóstico de diabetes, que es justo lo que se buscaba, y con una dispersión residual más del doble en el grupo diabético. La restricción del formalismo se verificó empíricamente: al intentar el arco inverso **wc** → **dm** —un nodo discreto con padre continuo— el ajuste falla con “*arc wc → dm violates the assumptions of the model*”. Esto tiene una consecuencia concreta sobre la DAG 1, que terminaba en **wc** → **classification**: con esa orientación el diagnóstico no puede entrar a la red, y habría que invertir el arco y tratarlo como causa de los hallazgos y no como su consecuencia.

3.6.2 ¿Dónde conviene colocar la diabetes?

El especialista la puso como padre de la glucosa por razones clínicas. Para contrastar esa decisión con los datos se evaluaron varias posiciones con el BIC condicional gaussiano sobre los 398 pacientes con **dm** registrada, tomando como referencia el modelo en que **dm** entra a la red pero sin arcos (Tabla 7). Como todos los modelos comparten las mismas variables y las mismas filas, los puntajes son comparables entre sí.

Tabla 7: Dónde colocar la diabetes: BIC condicional gaussiano ($n = 398$) según los nodos continuos de los que **dm** es padre.

Posición de dm	BIC	Ganancia
Sin arcos (nodo aislado)	−16,557.8	—
dm → bp	−16,547.9	+9.9
dm → sc	−16,539.3	+18.5
dm → bgr (<i>propuesta del especialista</i>)	−16,437.8	+120.0
dm → { bgr , bp }	−16,427.9	+129.9
dm → { bgr , sc }	−16,419.2	+138.5
dm → { bgr , bp , sc }	−16,409.4	+148.4
Búsqueda voraz: dm padre de los 13 nodos	−16,207.0	+350.7

La lectura tiene dos capas. La primera confirma al especialista: de todas las posiciones individuales, **la glucosa es con mucho la mejor** (+120.0 puntos, frente a +18.5 de la creatinina y +9.9 de la presión). El arco que la clínica dictaba es también el que los datos prefieren.

La segunda es una advertencia. Una búsqueda voraz sin restricciones termina colgando la diabetes de **los trece nodos**, con una ganancia de 350.7 puntos, y eso no debe leerse como que la diabetes causa todo el cuadro. En este dataset **los 137 pacientes diabéticos son, sin excepción, pacientes con ERC** —el análisis exploratorio encontró lo mismo en las diez variables binarias: su nivel positivo corresponde al 100 % de enfermos—, y como el 54.8 % de los enfermos son diabéticos, **dm** funciona como un **sustituto parcial del diagnóstico**. El algoritmo no está descubriendo fisiología, está reencontrando la etiqueta que se le quitó a la red. Conviene, por

tanto, fijar la posición de la variable discreta por criterio clínico y usar el puntaje solo para confirmarla.

3.6.3 El diagnóstico como raíz discreta

El caso límite del razonamiento anterior es meter el propio diagnóstico como nodo discreto raíz, padre de las 13 variables continuas. Bajo (5) esto equivale a ajustar **dos redes gaussianas**, una por grupo, y es la formalización natural de la conjetura del análisis exploratorio: si la no normalidad viene de mezclar enfermos y sanos, el modelo debería mezclarlos explícitamente.

El resultado es el mayor salto de ajuste de todo el estudio: el BIC pasa de $-16,374.2$ a $-14,486.5$, una ganancia de **1,887.7 puntos** a cambio de duplicar los parámetros (de 45 a 90). La ganancia no se reparte por igual: la Tabla 8 muestra qué nodos la piden.

Tabla 8: Ganancia en BIC al estratificar cada nodo por diagnóstico (una regresión por grupo en lugar de una común).

Nodo	ΔBIC	Nodo	ΔBIC	Nodo	ΔBIC	Nodo	ΔBIC
al	+592.9	bgr	+159.4	bu	+135.6	rc	+31.2
sc	+318.9	hemo	+145.9	pcv	+117.5	sod	+23.4
pot	+161.5	sg	+144.3	bp	+33.4	wc	+18.3
						age	+5.4

La albuminuria encabeza la lista por un margen enorme (+592.9), y la razón es la que el análisis exploratorio ya había detectado: **ningún paciente sano presenta albúmina en orina**, de modo que en ese grupo la variable es prácticamente una constante en cero y su varianza condicional es minúscula. Forzar una sola gaussiana para los dos grupos es, en su caso, un error grosero. Le siguen la creatinina, el potasio y la glucosa, los tres marcadores más asimétricos del conjunto. Solo la edad (+5.4) no justifica la estratificación, lo que también tiene sentido: es la única variable del modelo que no es una consecuencia de la enfermedad.

3.6.4 Cuánto cuesta la alternativa de discretizar

La segunda vía —discretizar todo y ajustar una red multinomial— tiene un costo que conviene cuantificar en lugar de mencionarlo al pasar. Al partir cada variable en tres intervalos de igual amplitud, **sc** coloca **397 de 400 pacientes (99.2 %)** en el **primer intervalo** y **pot** coloca 398 (99.5 %), dejando además un intervalo **vacío** —de ahí la advertencia que **bnlearn** emite sobre niveles no observados—. Con esa partición, las dos variables sobre las que giran cuatro de las seis consultas se vuelven, a efectos prácticos, constantes. Las variables simétricas se comportan mucho mejor: **hemo** reparte 25/199/176. La discretización por cuantiles, o con cortes clínicos —los estadios de la ERC, por ejemplo—, sería preferible a la de igual amplitud, pero seguiría descartando la información dentro de cada intervalo, que es justo la que las consultas de tipo $E[\cdot]$ necesitan.

3.7. Respuesta a las consultas

La Tabla 9 reúne las seis respuestas junto con la frecuencia observada en los datos sobre el mismo universo.

La red acierta el sentido de las seis consultas. La presión alta aumenta la probabilidad de creatinina elevada (0.556 contra una marginal de 0.235); el daño renal avanzado baja la hemoglobina; la hiperglucemia sube la albuminuria esperada, que pasa de 0.68 a 1.71; y los pacientes diabéticos tienen más riesgo de creatinina alta. Ninguna respuesta contradice la dirección que el especialista anticipaba al proponer la consulta.

Tabla 9: Respuesta a las seis consultas con la DAG 2 ajustada, frente a la evidencia observada. La última columna reporta el mayor coeficiente de asimetría entre las variables que intervienen.

	Consulta	Red	Observado	n	Error	sesgo
C1	$P(\text{sc} > 3 \mid \text{bp} \geq 90)$	0.556	0.417	84	+33.3 %	7.63
C2	$E[\text{pcv} \mid \text{hemo} < 10]$	27.111	25.848	75	+4.9 %	0.30
C3	$E[\text{hemo} \mid \text{sc} > 5]$	12.072	8.984	58	+34.4 %	7.63
C4	$P(\text{pot} > 5.5 \mid \text{bu} > 100)$	0.600	0.250	52	+140.0 %	12.50
C5a	$E[\text{al} \mid \text{bgr} < 140]$	0.682	0.695	258	−1.9 %	2.06
C5b	$E[\text{al} \mid \text{bgr} > 200]$	1.711	2.028	73	−15.6 %	2.06
C6	$P(\text{sc} > 3 \mid \text{dm} = \text{sí})$	0.561	0.409	137	+37.2 %	7.63

C6 se responde con la red gaussiana condicional; las demás, con la GBN de la DAG 2.

Las magnitudes son otra historia. En C1, C4 y C6 la red sobreestima la probabilidad, y en C3 no alcanza a bajar la hemoglobina tanto como lo hace el dato: predice 12.07 cuando lo observado es 8.98, apenas 0.4 puntos por debajo de la media marginal de 12.45. El caso extremo es C4, donde la red duplica y media la frecuencia observada de hiperkalemia. La siguiente sección muestra que estos errores no son aleatorios.

3.8. Diagnóstico del supuesto gaussiano

La Tabla 10 evalúa, sobre la base imputada, qué tan lejos está cada variable de la normal que la red le impone.

Tabla 10: Diagnóstico de normalidad sobre las 400 observaciones imputadas. SW es el p -valor de la prueba de Shapiro–Wilk [29]; las dos últimas columnas reportan la asimetría dentro de cada grupo diagnóstico.

Variable	Media	D.E.	Sesgo	Curtosis	SW p	Sesgo ckd	Sesgo notckd
age	51.50	16.98	−0.68	0.11	3×10^{-8}	−1.17	0.07
bp	76.42	13.49	1.63	8.85	8×10^{-18}	1.54	−0.27
sg	1.02	0.01	−0.09	−0.94	5×10^{-15}	0.47	0.07
al	1.10	1.35	1.04	0.46	2×10^{-22}	0.47	0.22
bgr	148.45	75.92	2.06	4.65	6×10^{-23}	1.48	−0.04
bu	57.36	49.62	2.65	9.52	3×10^{-25}	2.04	−0.08
sc	3.05	5.62	7.63	81.60	3×10^{-34}	6.38	2.58
sod	137.28	9.94	−7.04	84.21	7×10^{-30}	−7.29	0.22
pot	4.55	2.87	12.50	170.64	1×10^{-37}	10.06	−0.28
hemo	12.45	2.77	−0.28	−0.30	1×10^{-3}	−0.53	0.25
pcv	38.18	8.58	−0.30	−0.23	3×10^{-4}	−0.41	0.18
wc	8425.04	2527.65	1.85	9.14	2×10^{-17}	1.92	0.03
rc	4.55	0.94	0.02	0.06	0.10	0.26	0.27

El resultado es contundente: **solo 1 de las 13 variables (rc)** no rechaza la normalidad al 5 %. El análisis exploratorio había conjeturado que el problema venía de mezclar dos poblaciones —enfermos y sanos— y que condicionar por el diagnóstico rescataría el supuesto. Los datos matizan esa conjetura en dos sentidos. Por un lado **la conjetura acierta en la asimetría**: dentro del grupo sano, el sesgo de **bp** pasa de 1.63 a −0.27, el de **bu** de 2.65 a −0.08, el de **sod** de −7.04 a 0.22 y el de **pot** de 12.50 a −0.28; separar los grupos elimina casi toda la asimetría global. Por otro lado **el rechazo formal persiste**: dentro de **ckd** ninguna de las 13 pasa la prueba, y dentro de **notckd** solo una. Dos razones lo explican: la creatinina sigue fuertemente asimétrica incluso entre sanos (sesgo 2.58), y varias de las supuestas continuas son en realidad ordinales o redondeadas —**bp** en múltiplos de 10, **sg** en cinco niveles, **al** en seis—, de modo que

la prueba las rechaza por los empates, no por las colas.

El supuesto y el error van juntos. Al cruzar el error relativo de cada consulta (Tabla 9) con el mayor coeficiente de asimetría entre las variables que intervienen, la relación es monótona y fuerte: $\rho_{\text{Spearman}} = 0.898$ con $p = 0.006$. La consulta más precisa, C2, involucra hemoglobina y hematocrito, las dos variables mejor comportadas (sesgo ≈ 0.3), y yerra por 4.9 %. La menos precisa, C4, involucra al potasio, con sesgo 12.50 y curtosis 170.6, y yerra por 140 %.

Por qué falla la consulta 3. Vale la pena desarmar un caso porque el mecanismo es instructivo y no es el que uno supondría. La ecuación (7) no es la culpable: evaluada en los valores que realmente presenta el grupo con creatinina mayor a 5 ($\bar{bu} = 143.6$, $\bar{sc} = 11.83$), predice una hemoglobina de **9.56**, muy cerca del 8.98 observado. El problema está en el paso anterior. Bajo normalidad conjunta, condicionar sobre $sc > 5$ implica $E[sc \mid sc > 5] = 8.85$ y arrastra la urea solo hasta $E[bu \mid sc > 5] = 87.6$, cuando el grupo real promedia 143.6. Con esos valores atenuados, la misma ecuación devuelve 11.41 —esencialmente lo que la red reporta—. Es decir: **la gaussiana no subestima la relación entre creatinina y hemoglobina; subestima cuánto se acompañan las colas entre sí.** En un paciente con daño renal avanzado, la urea no sube "lo que la correlación lineal predice", sube mucho más, y esa co-ocurrencia de extremos es precisamente lo que una normal multivariada no puede representar.

3.9. ¿Mejoran los modelos no paramétricos el BIC y el AIC?

Con el supuesto gaussiano documentado como violado, la pregunta natural es si relajarlo mejora el ajuste. Se ajustaron nueve variantes de la DAG 2, todas sobre las mismas 400 observaciones y todas con la verosimilitud expresada **en la escala original** de los datos, combinando tres ingredientes: una transformación monótona de las marginales (Yeo–Johnson con λ estimado por máxima verosimilitud, o el caso particular $\lambda = 0$, que es $\log(1 + x)$), la estratificación por diagnóstico de §3.6.3, y la sustitución de la densidad normal de los residuos por un estimador kernel. La Tabla 11 reúne los resultados.

Tabla 11: Nueve variantes de la DAG 2. La verosimilitud está expresada en la escala original de los datos (con corrección jacobiana donde aplica). CV-5 es la log-verosimilitud fuera de muestra en cinco particiones. Los conteos de parámetros marcados con * son nominales: no cuentan la flexibilidad real del estimador kernel.

	Modelo	Par.	$\log \hat{L}$	BIC	AIC	CV-5
M0	GBN gaussiana (línea base)	45	−16,239.4	−16,374.2	−16,284.4	−16,559.2
M1	+ Yeo–Johnson	58	−14,767.3	−14,941.1	−14,825.3	−15,034.6
M2	+ estratificada por diagnóstico	90	−14,216.8	−14,486.5	−14,306.8	−14,592.4
M3	Yeo–Johnson + estratificada	103	−13,595.4	−13,904.0	−13,698.4	−14,014.9
M4	KDE en los residuos	45*	−15,442.3	−15,577.1	−15,487.3	−16,472.5
M5	Yeo–Johnson + KDE	58*	−14,425.5	−14,599.2	−14,483.5	−16,397.0
M6	YJ + estratificada + KDE	103*	−12,445.6	−12,754.2	−12,548.6	−13,810.3
L1	$\log(1 + x)$	45	−15,476.5	−15,611.3	−15,521.5	−16,952.5
L3	$\log(1 + x)$ + estratificada	90	−14,050.0	−14,319.6	−14,140.0	−15,357.7

Sí mejora, y por mucho, pero no por donde uno esperaría. Los dos ingredientes que producen ganancias grandes y **consistentes en los tres criterios** son paramétricos o semi-paramétricos, no no paramétricos: transformar las marginales aporta +1,433 puntos de BIC y +1,525 de verosimilitud fuera de muestra sobre la línea base; estratificar por diagnóstico aporta +1,888 y +1,967; y juntos (M3) suman **+2,470** de BIC y +2,544 de CV. Que las tres medidas coincidan es lo que hace creíble la mejora.

El estimador kernel es otra historia, y es la parte instructiva. Por BIC nominal, M6

es el mejor modelo de la tabla por un margen amplio ($-12,754.2$, es decir $+3,620$ sobre la línea base). Pero ese número **no es comparable**, por la razón anticipada en §2.8: la penalización del BIC cuenta 103 parámetros cuando un estimador kernel con 400 observaciones tiene muchos más grados de libertad efectivos. Al medir fuera de muestra, la ventaja se desinfla: M6 supera a M3 por apenas 205 puntos de CV, contra los 1,150 que sugería el BIC. Y en las otras dos comparaciones el kernel directamente **pierde**: M4 mejora el BIC en 797 puntos sobre M0 pero solo 87 en validación cruzada, y M5 mejora el BIC en 342 puntos sobre M1 mientras **empeora** la validación cruzada en 1,362. La razón de esa fragilidad es la esperable en un estimador local: una observación de prueba que cae lejos de todos los residuos de entrenamiento recibe una densidad casi nula y aporta una log-verosimilitud enormemente negativa, algo que la cola gaussiana —por gruesa que sea— nunca hace.

Vale la pena mirar de dónde venía la ganancia aparente del kernel. Nodo por nodo, sobre los datos sin transformar se concentra en **pot** (+230), **sc** (+142), **bgr** (+125) y **al** (+89), y es **negativa** en los nodos bien comportados (**rc**, **hemo**). Es decir: el kernel no está capturando una no linealidad clínica, está absorbiendo colas extremas y **átomos** —el cero de la albuminuria, los múltiplos de 10 de la presión—. Después de transformar las marginales, la única ganancia que sobrevive con claridad sigue siendo la de **pot** (+187) y la de **al** (+71), las dos variables con masa puntual. La conclusión es que buena parte de lo que aquí parecía “no normalidad” es en realidad **discretitud**, y el remedio adecuado para eso no es un kernel sino declarar esas variables como lo que son —ordinales— dentro de una red mixta.

3.9.1 Un modelo utilizable: transformación logarítmica y estratificación

M3 es el mejor modelo por verosimilitud, pero tiene un defecto que solo aparece al usarlo. Los λ estimados son negativos en seis variables (**sc**: -0.95 ; **bp** y **al**: -0.68 ; **bgr**: -0.41), y una transformación de Yeo–Johnson con $\lambda < 0$ tiene **soporte acotado**: la transformada inversa $x = (\lambda z + 1)^{1/\lambda} - 1$ tiene una asíntota vertical en $z = -1/\lambda$. La gaussiana del espacio transformado no respeta esa cota, así que al simular aparecen valores devueltos astronómicos. En la práctica esto arruina las consultas sobre albuminuria: M3 estima $E[\text{al} \mid \text{bgr} < 140] = 11.1$ cuando lo observado es 0.695. **El mejor modelo de densidad no es automáticamente el mejor simulador.**

La corrección es fijar $\lambda = 0$, es decir usar $\log(1 + x)$, que es monótona, de soporte no acotado y —al no estimarse— **no consume parámetros**. El modelo resultante, L3, mejora el BIC en $+2,054.6$ puntos y la validación cruzada en $+1,201.5$ respecto de la línea base, y sí se puede simular. La Tabla 12 rehace las consultas con él.

Tabla 12: Las consultas respondidas con la GBN gaussiana original (M0) y con el modelo $\log(1 + x)$ + estratificado (L3), por muestreo directo de 4×10^5 realizaciones.

	Consulta	Obs.	M0	L3	Err. M0	Err. L3
C1	$P(\text{sc} > 3 \mid \text{bp} \geq 90)$	0.417	0.558	0.463	33.9 %	11.2 %
C2	$E[\text{pcv} \mid \text{hemo} < 10]$	25.848	27.088	26.656	4.8 %	3.1 %
C3	$E[\text{hemo} \mid \text{sc} > 5]$	8.984	12.066	10.266	34.3 %	14.3 %
C4	$P(\text{pot} > 5.5 \mid \text{bu} > 100)$	0.250	0.599	0.546	139.6 %	118.3 %
C5a	$E[\text{al} \mid \text{bgr} < 140]$	0.695	0.686	0.680	1.3 %	2.2 %
C5b	$E[\text{al} \mid \text{bgr} > 200]$	2.028	1.705	2.033	15.9 %	0.3 %
	Error relativo medio				38.3 %	24.9 %

La columna M0 reproduce, mediante un muestreador propio, los valores que **cpquery** entrega en la Tabla 9: 0.558 contra 0.556, 27.088 contra 27.111, 12.066 contra 12.072 y 0.599 contra 0.600. La diferencia es ruido de muestreo.

El error relativo medio baja de 38.3 % a 24.9 %, y la mejora se concentra justo donde el diagnóstico de §3.8 predecía: las consultas dominadas por variables asimétricas. C1 pasa de 33.9 % a 11.2 % de error, C3 de 34.3 % a 14.3 %, y C5b —la albuminuria bajo hiperglucemia— pasa de 15.9 % a 0.3 %. La única que sigue mal es C4, la hiperkalemia, y no sorprende: el potasio tiene un máximo de 47 mmol/L en una escala cuyo percentil 75 es 4.9, y ninguna transformación monótona global reconcilia eso con una gaussiana.

3.10. Contraste contra una estructura aprendida de los datos

Ninguna de las tres estructuras proviene de los datos, así que como extensión de este trabajo se ejecutó una **búsqueda voraz** (*hill-climbing*) sobre los mismos 400 registros, maximizando el BIC gaussiano de (3), implementada desde cero para poder inspeccionar cada paso. La red aprendida es:

```
[bgr][age|rc:bgr][bp|pcv][al|bgr][hemo|al]
[sg|hemo:sod:bgr][sod|al:bgr][bu|pcv:al:rc]
[sc|bu:sod:hemo][pot|bu:sod:sc][pcv|hemo:sg]
[rc|pcv:hemo][wc|sg]
```

Con 24 arcos alcanza un BIC de $-16,096.5$, **278 puntos por encima de la DAG 2**. Y sin embargo no es una estructura utilizable: incluye $rc \rightarrow age$ —el conteo de eritrocitos como causa de la edad— y $pcv \rightarrow bp$, orientaciones que ningún clínico aceptaría. La razón es conocida: dentro de una clase de equivalencia de Markov, varias orientaciones producen exactamente el mismo ajuste, y un criterio de *score* no tiene forma de preferir la correcta [2, 7].

El contraste delimita bien lo que aporta cada fuente. De los 19 arcos de la DAG 2, el algoritmo recupera 7 con la misma orientación —entre ellos $al \rightarrow bu$, $bgr \rightarrow al$, $bu \rightarrow pot$ y $hemo \rightarrow pcv$ — y 3 más invertidos, de modo que 10 de las 19 *adyacencias* propuestas por el especialista aparecen también en la solución de los datos. Los datos, en suma, confirman buena parte de las **conexiones** que el experto dibujó y no sirven para decidir su **dirección**; el experto aporta exactamente lo contrario. Un aprendizaje con lista blanca —que fije las orientaciones clínicamente indiscutibles y deje al algoritmo el resto— es la síntesis natural de ambos.

3.11. Limitaciones

El supuesto gaussiano no se cumple. Doce de las trece variables rechazan la normalidad, y el error de las consultas escala con la asimetría. La §3.9 muestra que la transformación logarítmica y la mezcla condicional recortan ese error de 38.3 % a 24.9 %, pero no lo eliminan: incluso con el modelo corregido, las respuestas deben leerse como el sentido y el tamaño relativo del efecto, no como probabilidades aplicables a un paciente concreto.

Variables ordinales tratadas como continuas. *bp*, *sg* y *al* tienen 10, 5 y 6 niveles observados. Además, la imputación les asigna valores intermedios que no existen en la escala de medición.

Imputación de punto único. Se usó una sola realización de MICE, de modo que la incertidumbre de la imputación no se propaga a las estimaciones. La práctica recomendada es generar varias imputaciones y combinar los resultados con las reglas de Rubin [17].

Redundancia entre variables. *hemo*, *pcv* y *rc* correlacionan entre 0.83 y 0.90: miden esencialmente lo mismo, y los arcos que los unen inflan el ajuste sin aportar mecanismo.

Universos pequeños en las colas. Las consultas se evalúan sobre 52 a 84 pacientes, salvo C5a. La frecuencia observada que sirve de referencia tiene, ella misma, un margen de error amplio.

Un solo hospital. Los 400 registros provienen de un mismo centro y un periodo de dos meses; nada garantiza que los coeficientes estimados se trasladen a otra población.

4. Conclusiones

El trabajo partió de una pregunta poco habitual en el modelado gráfico: en lugar de dejar que un algoritmo descubriera la estructura, se le pidió a tres personas con formación médica que dibujaran cómo creen que se relacionan los marcadores de laboratorio de la enfermedad renal crónica, y se sometió ese dibujo a los datos. Las tres propuestas coinciden en el tramo inicial de la cascada —la edad y las dos enfermedades de base deterioran la función de filtrado— y se separan al final, en cómo ese deterioro llega a la anemia. Ahí los criterios de información son inequívocos y además coinciden con la fisiología: la caída de la hemoglobina acompaña al deterioro del filtrado y no al desbalance electrolítico, que es lo que cabe esperar de una hormona producida por el propio riñón. La estructura seleccionada fue la de uno de los estudiantes de semestres avanzados, y la elección resultó estable frente a los dos criterios empleados y frente a una reimplementación independiente de los puntajes.

Sobre las consultas planteadas por los especialistas, la red responde bien la pregunta cualitativa y mal la cuantitativa. Reproduce el sentido de las seis: la presión arterial elevada se acompaña de mayor riesgo de creatinina alta, el daño renal avanzado deprime la hemoglobina, la hiperglucemia eleva la albuminuria esperada y los pacientes diabéticos presentan más riesgo renal, mientras que el hematocrito esperado ante hemoglobina baja se estima con buena precisión. Las magnitudes, en cambio, se alejan de lo observado justo donde las variables implicadas son más asimétricas, de modo que estas respuestas deben leerse como el sentido y el orden del efecto —qué grupo está en peor situación y aproximadamente por cuánto— y no como probabilidades aplicables a un paciente concreto. Identificar el origen de esa discrepancia fue una de las partes más productivas del estudio: lo que falla no es la relación que la red estima entre las variables, sino el supuesto de que sus colas se acompañan de forma lineal, porque en un paciente con daño avanzado los marcadores extremos aparecen juntos con mucha más frecuencia de la que una normal multivariada puede representar.

De ahí se desprenden tres lecciones sobre el método. La primera es que el conocimiento del experto y la evidencia de los datos aportan cosas distintas y complementarias: una búsqueda automática sobre el mismo conjunto encuentra un ajuste mejor y recupera buena parte de las conexiones que los especialistas dibujaron, pero orienta varias de ellas de formas clínicamente imposibles, porque un criterio de ajuste no distingue entre direcciones estadísticamente equivalentes. La segunda es que el formalismo tiene fronteras que conviene declarar: un grafo acíclico no admite retroalimentación, de modo que una observación correcta del especialista sobre el efecto de los electrolitos en la presión arterial quedó necesariamente fuera del modelo. La tercera es que las variables categóricas sí caben en una red gaussiana, a través de su versión condicional, siempre que se coloquen donde la clínica dice que van —al inicio de la cascada, como causas y no como consecuencias—; los datos confirmaron la posición que el especialista había elegido para la diabetes, aunque también advirtieron que dejar al algoritmo colocarla libremente equivale a reintroducir el diagnóstico por la puerta de atrás, dado que en este conjunto todos los pacientes diabéticos están enfermos.

El intento de relajar el supuesto gaussiano dejó una conclusión con valor metodológico propio. Los criterios de información premian generosamente a un estimador de densidad no paramétrico, pero ese premio no significa nada, porque la penalización que ambos criterios aplican supone una familia paramétrica de dimensión fija y no sabe cobrar la flexibilidad de un estimador local; evaluada fuera de muestra, esa ventaja aparente casi desaparece y en algunos casos se invierte. Las mejoras que sí resisten los tres criterios son de naturaleza semiparamétrica y sorprendentemente simples: transformar monótonamente las marginales antes de ajustar, y separar el modelo por diagnóstico, que no es otra cosa que la red gaussiana condicional discutida para las variables categóricas. Con ambas, la red no solo ajusta mejor: acorta de forma apreciable la distancia entre sus respuestas y lo observado, que era el objetivo original. Conviene añadir que el modelo con mejor verosimilitud no fue el más útil, porque su transformación restringe el soporte de las variables y arruina la simulación; ajuste y usabilidad no siempre apuntan al

mismo lugar.

Con estos resultados en la mano, el uso razonable del modelo es el de una herramienta de razonamiento clínico —ordenar hipótesis, anticipar qué marcadores conviene solicitar, discutir con un especialista si la estructura que dibujó se sostiene— y no el de un instrumento de decisión individual. Para acercarlo a ese segundo papel hay cuatro caminos naturales. Tratar como ordinales las variables que en realidad lo son, en lugar de forzarlas a la escala continua, atendería buena parte de la desviación que el estimador no paramétrico estaba absorbiendo. Ajustar una red semiparamétrica, que elija nodo por nodo el tipo de densidad mediante validación cruzada [22], evitaría imponer el mismo supuesto a todos los marcadores. Sustituir la imputación única por una múltiple llevaría la incertidumbre de los datos faltantes hasta las respuestas, que hoy se presentan como si esa incertidumbre no existiera. Y aprender la estructura con las orientaciones clínicas fijadas de antemano, evaluando la estabilidad de cada arco por remuestreo, permitiría que los datos aporten lo que saben hacer —descubrir conexiones no anticipadas— sin invadir aquello en lo que el experto es insustituible. Por encima de todas ellas está la validación en otra población: los pacientes analizados provienen de un solo hospital y un periodo breve, y ninguna conclusión sobre magnitudes debería trasladarse a otro contexto sin volver a estimarla.

Referencias

- [1] Pearl, J. (1988). *Probabilistic Reasoning in Intelligent Systems: Networks of Plausible Inference*. San Mateo, CA: Morgan Kaufmann.
- [2] Koller, D., & Friedman, N. (2009). *Probabilistic Graphical Models: Principles and Techniques*. Cambridge, MA: MIT Press.
- [3] Shachter, R. D., & Kenley, C. R. (1989). Gaussian influence diagrams. *Management Science*, 35(5), 527–550.
- [4] Geiger, D., & Heckerman, D. (1994). Learning Gaussian networks. En *Proceedings of the 10th Conference on Uncertainty in Artificial Intelligence*, 235–243.
- [5] Lauritzen, S. L., & Wermuth, N. (1989). Graphical models for associations between variables, some of which are qualitative and some quantitative. *The Annals of Statistics*, 17(1), 31–57.
- [6] Lauritzen, S. L. (1992). Propagation of probabilities, means and variances in mixed graphical association models. *Journal of the American Statistical Association*, 87(420), 1098–1108.
- [7] Chickering, D. M. (2002). Optimal structure identification with greedy search. *Journal of Machine Learning Research*, 3, 507–554.
- [8] Scutari, M. (2010). Learning Bayesian networks with the `bnlearn` R package. *Journal of Statistical Software*, 35(3), 1–22.
- [9] Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716–723.
- [10] Schwarz, G. (1978). Estimating the dimension of a model. *The Annals of Statistics*, 6(2), 461–464.
- [11] Lucas, P. J. F., van der Gaag, L. C., & Abu-Hanna, A. (2004). Bayesian networks in biomedicine and health-care. *Artificial Intelligence in Medicine*, 30(3), 201–214.
- [12] Kononenko, I. (2001). Machine learning for medical diagnosis: History, state of the art and perspective. *Artificial Intelligence in Medicine*, 23(1), 89–109.
- [13] Levey, A. S., & Coresh, J. (2012). Chronic kidney disease. *The Lancet*, 379(9811), 165–180.
- [14] Babitt, J. L., & Lin, H. Y. (2012). Mechanisms of anemia in CKD. *Journal of the American Society of Nephrology*, 23(10), 1631–1634.
- [15] Rubini, L., Soundarapandian, P., & Eswaran, P. (2015). *Chronic Kidney Disease* [Dataset]. UCI Machine Learning Repository. <https://doi.org/10.24432/C5G020>
- [16] Rubin, D. B. (1976). Inference and missing data. *Biometrika*, 63(3), 581–592.

- [17] Little, R. J. A., & Rubin, D. B. (2002). *Statistical Analysis with Missing Data* (2a ed.). Hoboken, NJ: Wiley.
- [18] van Buuren, S., & Groothuis-Oudshoorn, K. (2011). mice: Multivariate imputation by chained equations in R. *Journal of Statistical Software*, 45(3), 1–67.
- [19] Box, G. E. P., & Cox, D. R. (1964). An analysis of transformations. *Journal of the Royal Statistical Society, Series B*, 26(2), 211–252.
- [20] Yeo, I.-K., & Johnson, R. A. (2000). A new family of power transformations to improve normality or symmetry. *Biometrika*, 87(4), 954–959.
- [21] Hofmann, R., & Tresp, V. (1996). Discovering structure in continuous variables using Bayesian networks. En *Advances in Neural Information Processing Systems*, 8, 500–506.
- [22] Atienza, D., Bielza, C., & Larrañaga, P. (2022). Semiparametric Bayesian networks. *Information Sciences*, 584, 564–582.
- [23] Liu, H., Lafferty, J., & Wasserman, L. (2009). The nonparanormal: Semiparametric estimation of high-dimensional undirected graphs. *Journal of Machine Learning Research*, 10, 2295–2328.
- [24] Elidan, G. (2010). Copula Bayesian networks. En *Advances in Neural Information Processing Systems*, 23, 559–567.
- [25] Moral, S., Rumí, R., & Salmerón, A. (2001). Mixtures of truncated exponentials in hybrid Bayesian networks. En *Symbolic and Quantitative Approaches to Reasoning with Uncertainty (ECSQARU)*, LNCS 2143, 156–167.
- [26] Shenoy, P. P., & West, J. C. (2011). Inference in hybrid Bayesian networks using mixtures of polynomials. *International Journal of Approximate Reasoning*, 52(5), 641–657.
- [27] Silverman, B. W. (1986). *Density Estimation for Statistics and Data Analysis*. Londres: Chapman & Hall.
- [28] Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The Elements of Statistical Learning* (2a ed.). Nueva York: Springer.
- [29] Shapiro, S. S., & Wilk, M. B. (1965). An analysis of variance test for normality (complete samples). *Biometrika*, 52(3/4), 591–611.
- [30] Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- [31] McKinney, W. (2010). Data structures for statistical computing in Python. En *Proceedings of the 9th Python in Science Conference*, 56–61.
- [32] R Core Team (2024). *R: A Language and Environment for Statistical Computing*. Viena: R Foundation for Statistical Computing.